

ISMAGI

Institut Supérieur de Management, d'Administration et de Génie Informatique

RAPPORT DE PHASE 0

Étude de Sélection du Modèle VLM

Système d'Inspection Automatisée des Ouvrages d'Art par Intelligence Artificielle

Auteur	Youssef Elhardouzi
Établissement	ISMAGI — Institut Supérieur de Management, d'Administration et de Génie Informatique
Structure d'accueil	CID — Conseil Ingénierie et Développement
Type de stage	Stage de Fin d'Études (PFE)
Encadrant entreprise	[À compléter]
Encadrant académique	[À compléter]
Date	Mars 2026

Table des Matières

1. Introduction et Contexte du Projet

- 1.1 Contexte général
- 1.2 Objectif du projet CID
- 1.3 Objectif de ce rapport

2. Construction du Dataset d'Entraînement

- 2.1 Source des données — Fascicules ITSEOA
- 2.2 Extraction automatisée
- 2.3 Familles de désordres couvertes
- 2.4 Schéma de stockage MongoDB

3. Méthodologie de Sélection du Modèle

- 3.1 Contexte de la décision
- 3.2 Source de données pour la présélection
- 3.3 Candidats retenus
- 3.4 Critères de notation pondérée

4. Expérimentation et Résultats

- 4.1 Protocole expérimental
- 4.2 Métriques automatiques : BLEU et ROUGE-L
- 4.3 Résultats quantitatifs
 - 4.3.1 Métriques matérielles
 - 4.3.2 Scores BLEU et ROUGE-L
- 4.4 Analyse qualitative des sorties

5. Scores de Référence Publiés

- 5.1 Open VLM Leaderboard

6. Décision Finale et Justification

- 6.1 Scores pondérés
- 6.2 Modèle retenu : Qwen2.5-VL-3B-Instruct
- 6.3 Modèles non retenus — analyse

7. Conclusion et Prochaines Étapes

- 7.1 Synthèse de la Phase 0
- 7.2 Feuille de route Phase 1
- 7.3 Données supplémentaires prévues

Références

1. Introduction et Contexte du Projet

1.1 Contexte général

L'inspection des ouvrages d'art — ponts, viaducs, murs de soutènement — constitue une activité critique pour la sécurité des infrastructures de transport. En France et au Maroc, cette inspection repose sur le référentiel IQOA (Image de la Qualité des Ouvrages d'Art) et sur les fascicules techniques de l'ITSEOA (Instruction Technique pour la Surveillance et l'Entretien des Ouvrages d'Art). Ces documents définissent une nomenclature précise de plusieurs centaines de désordres, chacun associé à des causes probables, une gravité IQOA, et des suites à donner.

Aujourd'hui, cette inspection est réalisée manuellement par des ingénieurs qualifiés, qui photographient les désordres sur le terrain et rédigent ensuite des commentaires d'inspection détaillés. Ce processus est coûteux en temps et en ressources humaines, et présente une variabilité inter-expert non négligeable.

1.2 Objectif du projet CID

Le projet CID (Système d'Inspection des ouvrages d'art par IA) vise à automatiser partiellement ce processus en développant un système capable d'analyser une photographie d'ouvrage d'art et de générer automatiquement un commentaire d'inspection professionnel en français, conforme aux standards ITSEOA.

Le système repose sur une architecture en trois phases :

- Phase 0 — Exploration et sélection du modèle : évaluation comparative des VLMs candidats
- Phase 1 — Fine-tuning QLoRA : adaptation du modèle sélectionné sur le dataset ITSEOA
- Phase 2 — Pipeline LangGraph : intégration dans un pipeline agentique de traitement des rapports d'inspection

1.3 Objectif de ce rapport

Ce rapport documente la Phase 0 du projet : la démarche méthodologique qui a conduit au choix du modèle de vision-langage (VLM) retenu pour le fine-tuning. Il présente la construction du dataset d'entraînement, les critères de sélection du modèle, les expérimentations conduites, et la décision finale justifiée.

2. Construction du Dataset d'Entraînement

2.1 Source des données — Fascicules ITSEOA

Le dataset d'entraînement est construit à partir des fascicules techniques de l'ITSEOA, et plus spécifiquement du Fascicule 21 « Surveillance et entretien des ouvrages d'art — Fiches pathologiques ». Ce document contient des fiches de désordres standardisées, chacune composée d'une image photographique illustrant le désordre et d'un commentaire d'inspection expert structuré.

Chaque fiche suit une structure systématique couvrant quatre dimensions analytiques :

- Description du désordre observable
- Causes probables (mécanismes de dégradation)
- Gravité selon la classification IQOA (de 1 à 3U/3E)
- Suites à donner (entretien courant, entretien spécialisé, réparation)

2.2 Extraction automatisée

Un script Python d'extraction automatisée a été développé pour parser les PDF du Fascicule 21 et extraire les paires image-commentaire. Le script détecte la structure des fiches (Layout A), extrait les images via PyMuPDF, et associe chaque image à son commentaire textuel correspondant.

Statistiques du dataset

214 paires image-commentaire valides extraites du Fascicule 21
Couverture : 92 fiches de désordres distinctes sur 10 familles
Format de stockage : MongoDB Atlas (inspection_db.itseoa_pairs)
Format de fallback : finetuning_dataset.json
Images : JPEG, résolution variable (300–600 dpi)
Commentaires : texte structuré en français, moyenne 280 caractères

2.3 Familles de désordres couvertes

Chapitre	Famille de désordres	Nb fiches	Nb paires
2	Dispositifs de retenue	19	30
3	Équipements de recueil et évacuation des eaux	3	3
4	Corniches et chaperons	28	57
5	Trottoirs et bordures	9	18
7	Drainage et étanchéité	8	19
8	Joints de chaussée	17	45
9	Étanchéité	5	8
10	Perrés et maçonneries	8	21
Total	8 familles actives	97	201+

Les fascicules 1 et 5 ont été exclus car ils contiennent des procédures générales sans fiches pathologiques illustrées. Le Fascicule 21, consacré exclusivement aux fiches pathologiques avec illustrations photographiques, constitue la source principale.

2.4 Schéma de stockage MongoDB

Chaque paire image-commentaire est stockée dans MongoDB Atlas selon le schéma suivant :

Champ	Type	Description
fiche_number	<i>String</i>	Numéro de fiche (ex. : 4.2)
defect_name	<i>String</i>	Intitulé du désordre
commentary_full	<i>String</i>	Commentaire expert complet en français
image_b64	<i>String (base64)</i>	Image encodée en base64
source_type	<i>String</i>	itseoa_fiche ou manual_upload
validated	<i>Boolean</i>	Statut de validation expert

3. Méthodologie de Sélection du Modèle

3.1 Contexte de la décision

Le choix du modèle de vision-langage (VLM) est une décision centrale dans le projet CID. Ce modèle constituera le cœur du système — il sera fine-tuné sur notre dataset ITSEOA et utilisé en production dans le pipeline d'inspection. Une mauvaise décision à ce stade aurait des conséquences sur toutes les phases suivantes du projet.

Deux contraintes matérielles structurent la sélection : l'entraînement est conduit sur GPU NVIDIA T4 (15 GB VRAM, Google Colab gratuit), et la technique de fine-tuning retenue est QLoRA (Quantized Low-Rank Adaptation), qui réduit les besoins mémoire d'un facteur 4 en chargeant les poids du modèle en quantification 4-bit.

3.2 Source de données pour la présélection

La présélection des candidats repose sur le Open VLM Leaderboard (OpenCompass), qui évalue les modèles open-source sur 23 benchmarks multimodaux standardisés dont MMBench, MMStar, MMMU, et OCRBench. Le leaderboard a été filtré selon les critères suivants :

- Taille du modèle : $\leq 4\text{B}$ paramètres (contrainte T4 avec QLoRA)
- Disponibilité publique sur HuggingFace Hub
- Architecture native HuggingFace (interface AutoModel standard)
- Support LLaMA-Factory confirmé pour le fine-tuning

Les modèles classés au-dessus du top 15 ont été exclus car trop récents (BlueLM-2.6-3B, évalué post-soumission) ou utilisant des pipelines de chargement non standards incompatibles avec l'environnement T4 (SAIL-VL, QTuneVL).

3.3 Candidats retenus

Rang	Modèle	Params	Avg board	Organisation	Statut
#10	InternVL3-2B-hf	2B	64.5	OpenGVLab	Retenu
#11	Qwen2.5-VL-3B-Instruct	3B	64.5	Alibaba/Qwen	Retenu
~#13	Gemma3-4B-IT	4B	~63	Google DeepMind	Retenu
—	SmoIVLM2-2.2B-Instruct	2.2B	~55	HuggingFace	Référence

SmoIVLM2-2.2B a été inclus comme modèle de référence (baseline) pour fournir un point de comparaison à faible coût mémoire. InternVL2-2B, modèle initialement envisagé, a été exclu car son architecture non standard est incompatible avec l'interface HuggingFace et avec LLaMA-Factory.

3.4 Critères de notation pondérée

La décision finale repose sur cinq critères pondérés, chacun reflétant un aspect critique pour notre cas d'usage :

Critère	Poids	Justification
Qualité visuelle (leaderboard)	25%	Capacité de base à comprendre des images

Critère	Poids	Justification
avg)		structurelles
ROUGE-L moyen (3 images ITSEOA)	20%	Similarité lexicale avec commentaires experts (mesure expérimentale)
Capacité en langue française	20%	Dataset entièrement en français — vocabulaire technique ITSEOA
Compatibilité fine-tuning (LLaMA-Factory)	20%	Critère bloquant — Phase 1 dépend entièrement de ce support
Efficacité matérielle (VRAM + vitesse)	15%	Contrainte T4 (15 GB) et débit pour pipeline Phase 2

4. Expérimentation et Résultats

4.1 Protocole expérimental

Chaque modèle a été évalué sur trois images réelles extraites du dataset ITSEOA, couvrant trois familles de désordres distinctes. Ce choix de trois images vise à tester la robustesse des modèles sur des domaines visuels et textuels différents plutôt que de se limiter à une seule image qui pourrait favoriser ou défavoriser arbitrairement un modèle.

Index	Fiche	Désordre	Famille
12	2.9	Désordres sur les parapets en maçonnerie	Dégradation biologique / surface
38	4.2	Éclats résultant de la corrosion des armatures	Béton armé structural
116	7.2	Écoulement en intrados de tablier	Infiltration d'eau

Le protocole de chargement est uniforme pour tous les modèles : quantification 4-bit NF4 (BitsAndBytesConfig), device_map='auto', sans FlashAttention. Le prompt d'inspection est identique pour tous les modèles et toutes les images. La génération se fait en mode déterministe (do_sample=False, max_new_tokens=400).

4.2 Métriques automatiques : BLEU et ROUGE-L

Deux métriques automatiques mesurent la similarité lexicale entre la sortie du modèle et le commentaire expert de référence :

- BLEU (Bilingual Evaluation Understudy) : précision des bigrammes et trigrammes communs, avec lissage pour les sorties courtes
- ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation) : longueur de la plus longue sous-séquence commune, normalisée en F-mesure

Ces scores mesurent la proximité du vocabulaire utilisé par le modèle avec celui d'un ingénieur expert. Des valeurs absolues faibles (ROUGE-L 0.10–0.20) sont attendues en inférence zero-shot — les modèles n'ont pas encore été entraînés sur notre domaine. L'objectif est la comparaison relative entre modèles.

4.3 Résultats quantitatifs

4.3.1 Métriques matérielles

Modèle	Rang LB	VRAM (GB)	Temps moy. (s)	≈ Tokens/s	Note
InternVL3-2B-hf	#10	1.81	40.4	5.5	Meilleure vitesse
Qwen2.5-VL-3B	#11	2.43	50.7	4.6	★ Sélectionné
Gemma3-4B-IT	~#13	3.24	61.1	3.9	Plus lent
SmolVLM2-2.2B	—	1.89	14.7	5.9	Sorties incohérentes

4.3.2 Scores BLEU et ROUGE-L

Modèle	BLEU moy.	ROUGE-L moy.	ROUGE-L img 38	ROUGE-L img 116	Rang ROUGE
Qwen2.5-VL-3B	0.0579	0.1452	0.1752	0.1542	#1
InternVL3-2B-hf	0.0428	0.1375	0.1333	0.1626	#2
Gemma3-4B-IT	0.0471	0.1323	0.1391	0.1622	#3
SmolVLM2-2.2B	0.0046	0.0742	0.0885	0.0820	#4

4.4 Analyse qualitative des sorties

Au-delà des métriques automatiques, l'analyse des textes générés révèle des différences qualitatives importantes entre les modèles.

Image 38 — Éclats résultant de la corrosion des armatures (Fiche 4.2)

Cette image représente un désordre critique en béton armé. Le commentaire expert fait référence au faible enrobage, à la carbonatation, aux chlorures, et à la section réduite des armatures — un vocabulaire très spécifique.

- Gemma3-4B : meilleure qualité descriptive — « perte de matière importante, fragments de béton brisés, corrosion des armatures d'acier apparentes, traces d'eau stagnante ». Vocabulaire proche de l'expert.
- Qwen2.5-VL-3B : bonne identification — « zones de corrosion, débris de béton, barrière instable ». Moins précis mais structuré.
- InternVL3-2B : correct — « béton endommagé, taches de rouille, support métallique abîmé ». Vocabulaire approprié.
- SmolVLM2-2.2B : sortie aberrante — « maladie du poumon, maladie de l'estomac » (boucle de répétition). Éliminé.

Image 116 — Écoulement en intrados de tablier (Fiche 7.2)

Cette image montre des traces d'écoulement sous une dalle de pont. Le commentaire expert mentionne la gargouille, le tuyau de descente d'eau, et la chape d'étanchéité.

- Qwen2.5-VL-3B : « corrosion autour d'une ouverture, contact avec l'eau » — reconnaît le contexte hydraulique.
- InternVL3-2B : « décoloration sur le plafond, cavité apparente » — description correcte mais générique.
- Gemma3-4B : « écoulement de liquide brun-rougeâtre, trou circulaire, présence de rouille » — description la plus détaillée.

Note importante : l'absence des termes techniques spécifiques (gargouille, chape d'étanchéité) dans toutes les sorties est attendue en inférence zero-shot. Ces termes seront acquis lors du fine-tuning sur le dataset ITSEOA.

5. Scores de Référence Publiés

5.1 Open VLM Leaderboard

Les scores suivants sont issus du Open VLM Leaderboard (OpenCompass) et des rapports techniques officiels de chaque modèle. Ces benchmarks évaluent la compréhension visuelle générale et ne sont pas spécifiques à l'inspection d'ouvrages d'art.

Modèle	Param s	Avg LB	MMBench	MMStar	OCRBen ch	Licence
InternVL3-2B-hf	2B	64.5	78.0	61.1	831	MIT
Qwen2.5-VL-3B	3B	64.5	76.8	56.3	828	Apache 2.0
Gemma3-4B-IT	4B	~63	79.4	~56	~750	Gemma ToU
SmolVLM2-2.2B	2.2B	~55	~67	46.0	~600	Apache 2.0

Source : Open VLM Leaderboard (OpenCompass), rapports techniques officiels et model cards HuggingFace, Mars 2026. Les valeurs préfixées ~ sont estimées par interpolation depuis les rapports de la famille de modèles.

6. Décision Finale et Justification

6.1 Scores pondérés

Modèle	Visuel / 25	ROUG E-L /20	Français /20	Fine-tuning /20	Matériel / 15	TOTAL /100
Qwen2.5-VL-3B	23.0	9.7	18.0	19.0	10.2	79.9
SmolVLM2-2.2B	19.6	4.9	8.0	19.0	12.7	64.2
Gemma3-4B-IT	22.5	8.8	20.0	19.0	7.1	77.4
InternVL3-2B-hf	23.0	9.2	15.0	19.0	11.3	77.5

Note : Les scores ROUGE-L et matériels sont calculés à partir des mesures expérimentales sur Google Colab T4. Les scores français reflètent le nombre de langues d'entraînement et la présence confirmée de corpus français techniques dans les données d'entraînement.

6.2 Modèle retenu : Qwen2.5-VL-3B-Instruct

★ **Modèle retenu pour le fine-tuning Phase 1**

Qwen2.5-VL-3B-Instruct — Alibaba / Qwen — Rang #11 Open VLM Leaderboard Score pondéré : 79.9/100 | ROUGE-L moyen : 0.1452 | VRAM : 2.43 GB | Licence : Apache 2.0

La sélection de Qwen2.5-VL-3B-Instruct repose sur les arguments suivants :

- ROUGE-L le plus élevé (0.1452) — meilleure proximité lexicale avec les commentaires experts ITSEOA en inférence zero-shot. Ce score prédit une meilleure base d'apprentissage pour le fine-tuning.
- 29 langues d'entraînement incluant le français — la tokenisation française est native et le vocabulaire technique du génie civil est présent dans les données pré-entraînement.
- Licence Apache 2.0 — autorisant l'utilisation commerciale et académique sans restriction, contrairement à la Gemma Terms of Use de Google.
- Support LLaMA-Factory confirmé via le template qwen2_5_vl, testé et documenté par la communauté.
- Efficacité matérielle : 2.43 GB VRAM en 4-bit, laissant 12.6 GB disponibles sur T4 pour les activations et les gradients pendant le fine-tuning.

6.3 Modèles non retenus — analyse

Gemma3-4B-IT

Gemma3 a produit les descriptions les plus détaillées et les plus précises en inférence zero-shot, notamment sur l'image de corrosion des armatures. Son score ROUGE-L (0.1323) est inférieur à Qwen malgré une meilleure qualité subjective — cela s'explique par un style de rédaction plus verbeux qui dilue les termes clés.

Non retenu pour trois raisons : (1) consommation mémoire supérieure (3.24 GB vs 2.43 GB), laissant moins de marge pour le fine-tuning ; (2) vitesse d'inférence inférieure (3.9 vs 4.6 tokens/s), problématique pour le pipeline Phase 2 ; (3) licence Gemma Terms of Use plus restrictive qu'Apache 2.0.

InternVL3-2B-hf

InternVL3-2B-hf est une alternative très compétitive — ROUGE-L de 0.1375 (proche de Qwen), VRAM de 1.81 GB (le plus faible), et vitesse la plus élevée (5.5 tokens/s). Il surpasse Qwen sur l'image 116 (ROUGE-L 0.1626 vs 0.1542). En cas de problèmes avec Qwen lors du fine-tuning, InternVL3-2B-hf est le premier candidat de substitution.

SmoIVLM2-2.2B

SmoIVLM2-2.2B est formellement éliminé. Ses sorties sont des boucles de répétition incohérentes (« maladie du poumon », « maladie de l'estomac » pour une image de pont) sans aucun rapport avec le domaine d'inspection. Son ROUGE-L moyen (0.0742) est deux fois inférieur au candidat suivant. Malgré son faible encombrement mémoire, ce modèle est inadapté à notre cas d'usage.

7. Conclusion et Prochaines Étapes

7.1 Synthèse de la Phase 0

La Phase 0 a atteint ses deux objectifs : (1) construire un dataset d'entraînement de 214 paires image-commentaire à partir des fascicules ITSEOA, et (2) sélectionner le modèle VLM le plus adapté au fine-tuning sur données d'inspection en français.

La démarche de sélection est rigoureuse et reproductible : présélection depuis le Open VLM Leaderboard (top 15, $\leq 4B$ paramètres), filtrage par faisabilité technique, évaluation expérimentale sur 3 images réelles du domaine, scoring pondéré sur 5 critères objectifs. Le modèle Qwen2.5-VL-3B-Instruct est retenu avec un score de 79.9/100.

7.2 Feuille de route Phase 1

La Phase 1 consiste à fine-tuner Qwen2.5-VL-3B-Instruct sur le dataset ITSEOA en utilisant LLaMA-Factory avec la méthode QLoRA. Les paramètres retenus sont :

- LoRA rank : 16, alpha : 32, dropout : 0.05
- Quantification : 4-bit NF4 (BitsAndBytesConfig)
- Epochs : 3, batch effectif : 16 (2×8 gradient accumulation steps)
- Learning rate : 2×10^{-4} avec scheduler cosinus et warmup 3%
- Template LLaMA-Factory : qwen2_5_vl
- Données : 193 paires d'entraînement, 21 paires de validation (split 90/10)

7.3 Données supplémentaires prévues

Le dataset de 214 paires sera enrichi dans les phases suivantes par :

- Dataset GYU-DET : ~10 000 images annotées de désordres sur ponts-poutres (6 classes : crack, spallation, seepage, honeycomb, exposed_rebar, hole)
- Rapports de terrain confidentiels : images et commentaires issus des inspections terrain de CID (accès en entreprise)

Ces données supplémentaires alimenteront une version étendue du fine-tuning pour améliorer les performances du modèle sur des conditions réelles d'inspection.

Références

- ITSEOA — Instruction Technique pour la Surveillance et l'Entretien des Ouvrages d'Art, Fascicule 21, SETRA/LCPC
- IQOA — Image de la Qualité des Ouvrages d'Art, Ministère de l'Équipement
- DT375 — Guide d'inspection des ouvrages d'art, CEREMA
- Open VLM Leaderboard, OpenCompass, huggingface.co/spaces/opencompass/open_vlm_leaderboard, Mars 2026
- Qwen2.5-VL Technical Report, Alibaba/Qwen Team, 2025
- InternVL3 Technical Report, OpenGVLab, Shanghai AI Lab, 2025
- Gemma 3 Technical Report, Google DeepMind, 2025
- LLaMA-Factory: Unified Efficient Fine-Tuning of 100+ Language Models, Hiyouga et al., 2024
- QLoRA: Efficient Finetuning of Quantized LLMs, Dettmers et al., NeurIPS 2023

- Hu et al. — LoRA: Low-Rank Adaptation of Large Language Models, ICLR 2022